Um estudo de caso sobre Correlação Atrous (Dilatada)

Adriel F. Trajano, Kamily A. de Oliveira

[1]Centro de Informática – Universidade Federal da Paraíba (UFPB)
João Pessoa, PB, Brasil

adriel.ferreira@academico.ufpb.br

kamilyfacul@gmail.com

Resumo. *Este relatório apresenta o desenvolvimento de um sistema de Processamento Digital de Imagens em python, capaz de aplicar operações de correlação dilatada em imagens RGB com parâmetros configuravéis.*

1. Introdução

O Processamento Digital de Imagens (PDI) é uma área fundamental da computação que permite extrair, transformar e analisar informações presentes em imagens digitais. Técnicas de filtragem espacial são amplamente utilizadas para realizar operações como suavização, realce de bordas e detecção de padrões.

Entre essas operações, a correlação espacial é uma das mais importantes. Ela consiste na aplicação de uma máscara (kernel) sobre a imagem, realizando operações matemáticas entre os elementos da máscara e os pixels da imagem. Essa técnica permite implementar diversos tipos de filtros, desde filtros de média até detectores de borda.

Neste projeto foi implementado um sistema de filtragem baseado na operação de correlação dilatada conhecida como *Atrous Convolution*. Essa variação permite ampliar o campo de análise da máscara sem aumentar o número de parâmetros do filtro. A implementação foi feita manualmente em Python, evitando o uso de funções prontas de bibliotecas especializadas. Dessa forma, foi possível compreender em maior profundidade como essas operações são executadas internamente.

Além disso, o sistema permite configurar os parâmetros de stride (passo), taxa de dilatação e função de ativação, possibilitando analisar experimentalmente como esses fatores influenciam o resultado do processamento.

1.1. Objetivos do Projeto

O objetivo principal deste trabalho é desenvolver um sistema capaz de aplicar operações de correlação dilatada em imagens RGB, com experimentação de diferentes filtros e parâmetros.

Entre os objetivos específicos do projeto estão:

- Implementar manualmente a operação de correlação dilatada em imagens RGB.
- Permitir a configuração de parâmetros como stride, taxa de dilatação e função de ativação por meio de arquivos externos.
- Aplicar filtros clássicos de processamento de imagens, como filtro Gaussiano, Box (Média) e Sobel.
- Comparar os resultados da implementação manual com implementações equivalentes utilizando a biblioteca OpenCV.

2. Métodos

O projeto foi organizado em etapas que seguem o fluxo clássico de processamento digital de imagens: carregamento da imagem, leitura de parâmetros externos, aplicação de filtros espaciais, visualização e comparação dos resultados.

Todas as funções principais foram implementadas manualmente, utilizando operações matematicas básicas e apenas as bibliotecas essenciais.

2.1. Carregamento de Imagens

Inicialmente, são carregadas as imagens que serão usadas ao longo de toda a aplicação.

Figure 1. Imagem PeB

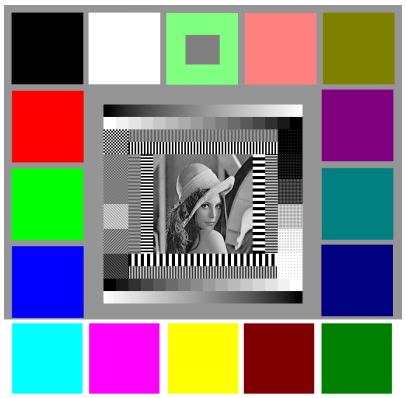

Figure 2. Imagem Colorida

Para a leitura das imagens foi utilizada a classe `Image` da biblioteca PIL. Após o carregamento, a imagem é convertida para uma matriz tridimensional representando os três canais de cor no formato RGB de 24 bits (8 bits por canal).

Cada pixel é representado por três valores inteiros no intervalo $[0, 255]$, correspondendo às intensidades dos canais vermelho (R), verde (G) e azul (B).

Assim, uma imagem pode ser representada matematicamente como uma função discreta:

$$I(x, y) = [R(x, y), G(x, y), B(x, y)] \tag{1}$$

onde (x, y) representa a posição espacial do pixel na imagem.

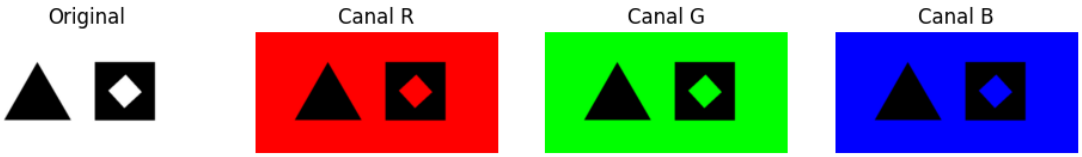

Figure 3. Imagem PeB

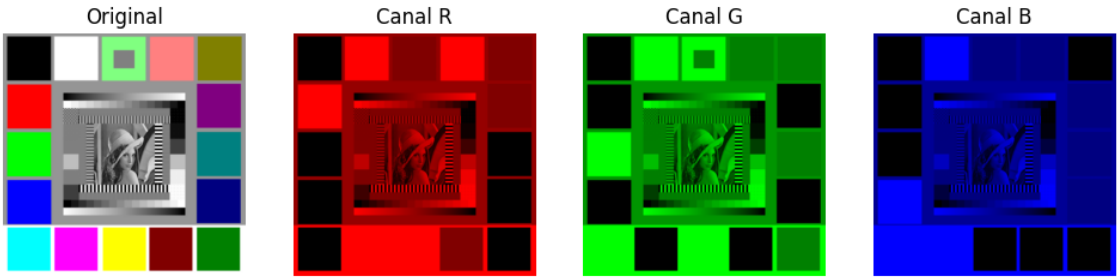

Figure 4. Imagem Colorida

Após a leitura, a imagem é convertida para uma estrutura de matriz NumPy para facilitar as operações matemáticas e iterativas necessárias para a aplicação dos filtros.

2.2. Leitura e Validação de Parâmetros

Os parâmetros de execução do sistema foram definidos em um arquivo externo no formato JSON. Esse arquivo contém exatamente as seguintes informações:

- valor do stride (passo)
- taxa r (dilatação)
- dimensões do filtro
- a matrix que representa o filtro
- função de ativação utilizada (ou ReLu ou Identidade)

A utilização de um arquivo externo permite alterar o comportamento do algoritmo sem modificar diretamente o código, facilitando a experimentação com diferentes configurações.

Logo após a leitura, os parâmetros são validados para garantir que valores inválidos não causem erros durante a execução, além de certificar uma amostragem mais controlada.

2.3. Correlação Espacial: base

A base da operação principal (dilatada) da aplicação é a correlação espacial entre uma máscara e a imagem.

Matematicamente, a correlação simples é definida como:

$$g(x, y) = \sum_{i=-k}^{k} \sum_{j=-k}^{k} f(x + i, y + j) \cdot w(i, j) \tag{2}$$

onde:

- $f(x, y)$ é a imagem de entrada
- $w(i, j)$ é a máscara do filtro
- $g(x, y)$ é a imagem resultante

Nessa etapa, cada posição da máscara é multiplicada pelo pixel correspondente da imagem e os resultados são somados. Essa operação é repetida para todos os pixels da imagem, gerando uma nova imagem: agora com a mascara aplicada.

2.4. Correlação Dilatada (Atrous)

Enquanto na correlação tradicional os elementos da máscara são aplicados em pixels adjacentes, na correlação dilatada existe um espaçamento controlado pelo parâmetro de dilatação r.

A equação passa a ser:

$$g(x, y) = \sum_{i=-k}^{k} \sum_{j=-k}^{k} f(x + r \cdot i, y + r \cdot j) \cdot w(i, j) \tag{3}$$

Isso faz com que os pontos da máscara fiquem mais esparsos entre si, aumentando o campo de análise do filtro sem aumentar o número de parâmetros.

2.5. Stride (Passo)

O parâmetro de stride controla o deslocamento da máscara sobre a imagem.

Quando o stride é igual a 1, o filtro percorre todos os pixels da imagem. Já quando o stride é maior que 1, o filtro pula posições durante a varredura. Dentro da nossa analise strides menores que zero não foram analisados.

Matematicamente, a posição da máscara passa a ser atualizada como:

$$x = x + s \tag{4}$$

$$y = y + s \tag{5}$$

onde s representa o valor do stride.

Quando o stride aumenta:

- a resolução da saída diminui
- menos posições são analisadas
- o processamento se torna mais rápido
- reduz custo computacional

Mas é preciso ter cuidado. Um aumento inpensado pode gerar:

- perda de detalhes da imagem
- o kernel pode pular regiões de borda
- perda de padrões (aliasing)

2.6. Função de Ativação ReLU

Esse projeto suporta duas funções de ativação: identidade e ReLU. Sendo o primeiro aquele que mantém os valores calculados na correlação. Enquanto isso, o ReLU (Rectified Linear Unit) é definido por:

$$ReLU(x) = \max(0, x) \tag{6}$$

E mantém apenas os valores positivos gerados, negativos são convertidos para zero.

Na prática, isso gera situações em que apenas bordas associadas a gradientes positivos são preservadas. Bordas cujo gradiente é negativo são completamente eliminadas, não sendo detectadas pelo filtro.

O exemplo abaixo evidência essa perda quando usamos um filtro de sobel vertical comum somado a uma função de ativação ReLU:

Figure 5. Sobel Vertical com Identidade

Figure 6. Sobel Vertical com ReLU

2.7. Filtro Box (Média)

O filtro de média, também conhecido como Box Filter, realiza uma operação de suavização na imagem. Essa operação consiste em substituir o valor de cada pixel pela média dos valores presentes em sua vizinhança.

Para uma máscara 3×3, a operação pode ser representada por:

$$g(x, y) = \frac{1}{9} \sum_{i=-1}^{1} \sum_{j=-1}^{1} f(x + i, y + j) \tag{7}$$

Esse tipo de filtro reduz variações bruscas de intensidade, produzindo um efeito de suavização ou desfoque na imagem.

Durante os experimentos, foi possível observar que a presença de valores muito maiores dentro da vizinhança pode influenciar significativamente o resultado da média. Por exemplo, quando usamos filtros 10x1, 1x10 ou 10x10, a intensidade elevada tende a aumentar o valor da dimensão. Esse comportamento explica por que filtros de média podem reduzir ruídos, mas também podem borrar bordas e detalhes importantes da imagem.

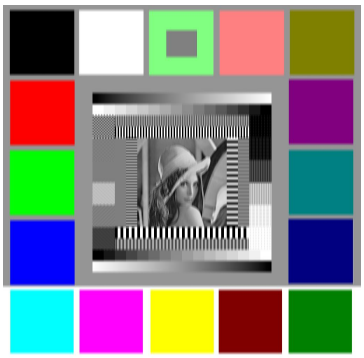

Figure 7. Filtro box 10x1

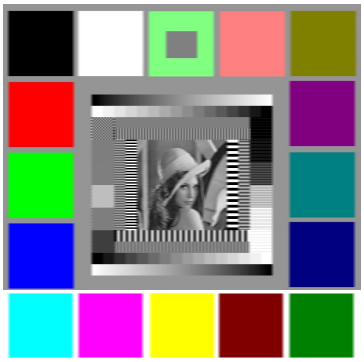

Figure 8. Filtro box 1x10

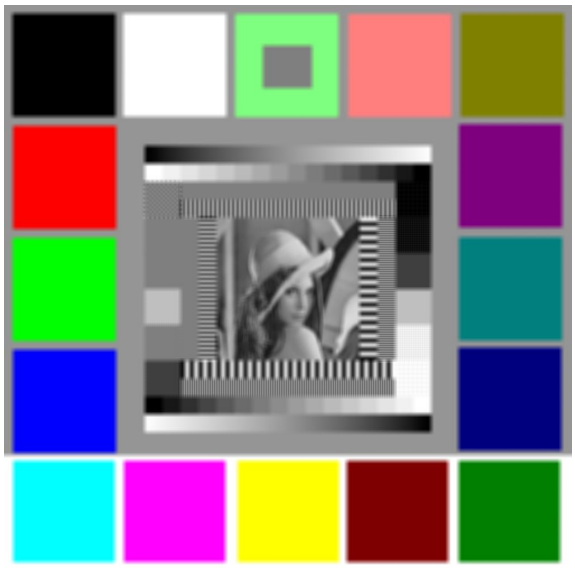

Figure 9. Filtro box 10x10

2.8. Operador de Sobel

O operador de Sobel é amplamente utilizado para detecção de bordas em imagens, aproximando as derivadas espaciais da imagem nas direções horizontal e vertical.

As máscaras utilizadas são:

$$G_h = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \tag{8}$$

$$G_v = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \tag{9}$$

Essas máscaras estimam a variação da intensidade da imagem nas direções horizontal e vertical, respectivamente.

Após a aplicação dos filtros, teremos dois mapas de gradiente G_h e G_v. A magnitude do gradiente pode ser calculada por:

$$G = \sqrt{G_x^2 + G_y^2} \tag{10}$$

ou pela aproximação computacional:

$$G = |G_x| + |G_y| \tag{11}$$

Regiões onde a magnitude do gradiente é elevada correspondem a mudanças abruptas de intensidade na imagem, caracterizando a presença de bordas.

Em alguns casos, os resultados podem gerar valores fora do padrão de exibição. Para lidar com isso, aplicamos, quando Sobel, a expansão de histograma.

2.9. Expansão de Histograma

Alguns operadores de detecção de bordas, no nosso caso Sobel, podem gerar valores de gradiente que ultrapassam o intervalo padrão de imagens de 8 bits $[0, 255]$.

Dependendo da intensidade das variações da imagem, os valores podem atingir o intervalo $[-765, 765]$. Entretanto, esse intervalo não pode ser representado por imagens de 8 bits. Para resolver esse problema, foi necessario aplicar uma normalização linear que mapeia os valores calculados para o intervalo válido da imagem:

$$I_{uint8} = round\left(\frac{I - min(I)}{max(I) - min(I)} \times 255\right) \tag{12}$$

Esse processo preserva as diferenças relativas entre os gradientes da imagem, permitindo que tanto bordas fortes quanto bordas fracas continuem visíveis após a conversão para o formato de 8 bits, no intervalo adequado.

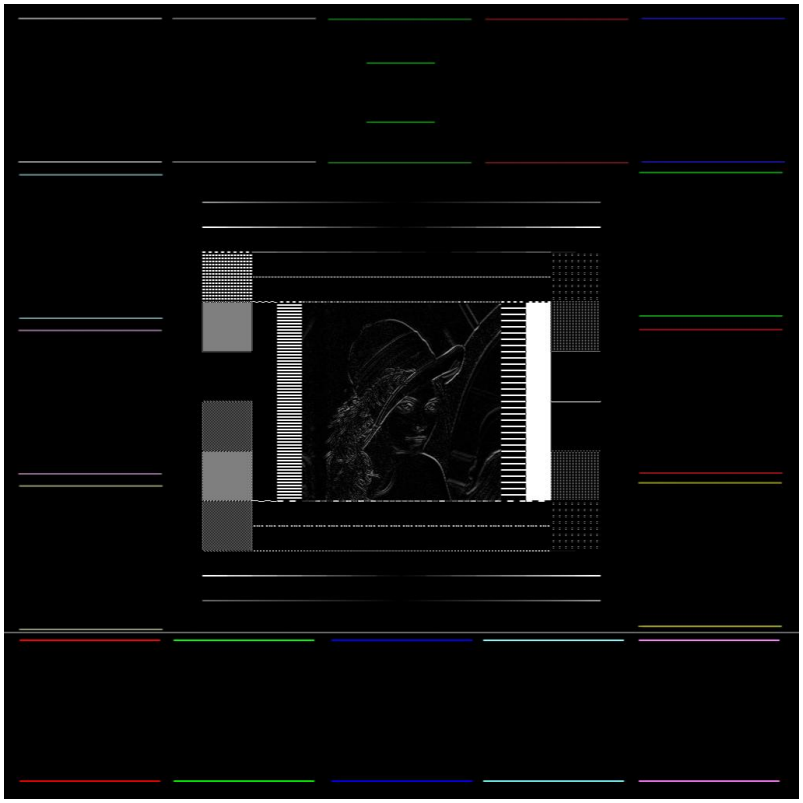

Figure 10. sobel com expansão de histograma

3. Comparação com OpenCV

Para verificar a corretude da implementação manual, foi realizada uma comparação com funções equivalentes disponíveis na biblioteca OpenCV.

No entanto, algumas diferenças surgiram entre as duas abordagens, principalmente por conta dos parâmetros configuraveis do projeto. Bibliotecas como OpenCV possuem otimizações internas e comportamentos padrão que podem diferir de uma implementação manual, como diferentes estratégias de tratamento de borda ou normalização automática dos resultados.

Para garantir uma comparação justa, foram realizadas adaptações forçadas no uso do OpenCV para que ele operasse em condições semelhantes às utilizadas na implementação manual. Isso incluiu a utilização de máscaras equivalentes, o controle da função de ativação - que por padrão é a identidade - e a remoção de algumas otimizações automáticas da biblioteca.

Com essas adaptações, foi possível observar que os resultados produzidos pela implementação manual se aproximam significativamente daqueles obtidos com o OpenCV, validando o funcionamento do algoritmo desenvolvido.

4. Resultados

Abaixo alguns dos resultados mais interessantes:

Figure 11. gaussiano 5x5 relu pb

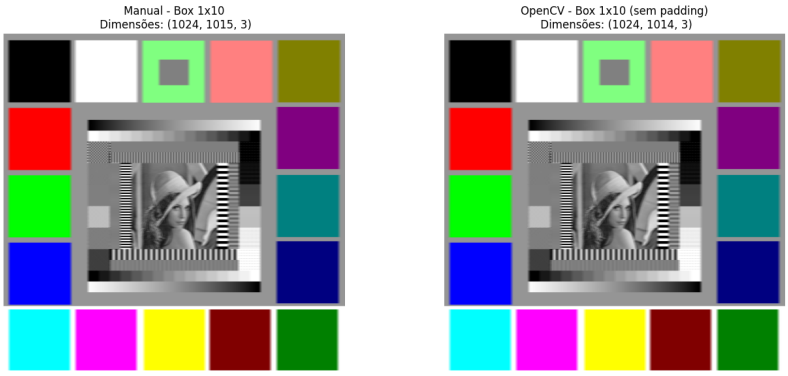

Figure 12. box 1x10 relu colorido

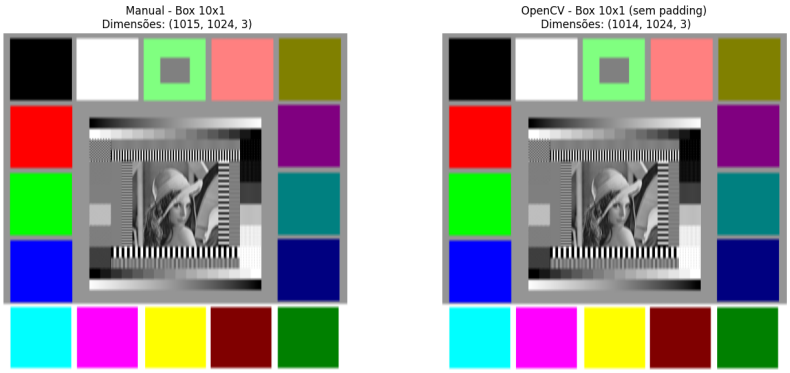

Figure 13. box 10x10 id colorido

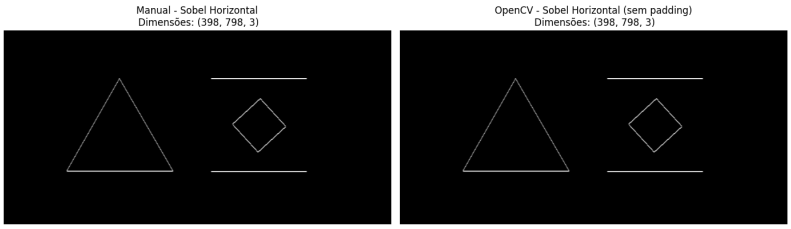

Figure 14. sobel horizontal id pb

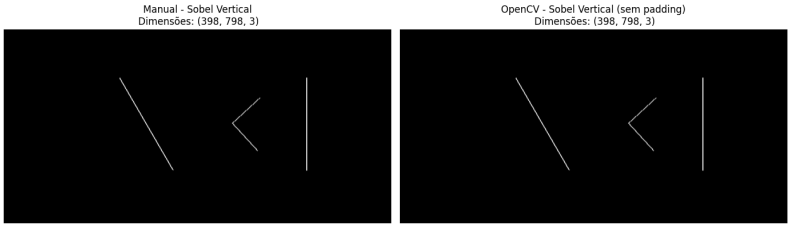

Figure 15. sobel vertical id pb

5. Discussão

Os experimentos demonstraram que a correlação dilatada permite analisar padrões espaciais amplos sem aumentar o tamanho da máscara necessariamente. Isso é devido principalmente aos pixels utilizados no cálculo poderem ser mais espaçados.

Outro fator importante observado foi o impacto do parâmetro stride. Quando o stride é aumentado, o filtro passa a percorrer a imagem com passos maiores, reduzindo o número de posições avaliadas. Como consequência, a imagem resultante apresenta menor resolução espacial.

Também foi possível observar o efeito da função de ativação ReLU. Como essa função elimina valores negativos, parte das bordas detectadas pelos filtros de gradiente deixa de aparecer. Isso ocorre porque as bordas podem produzir gradientes positivos ou negativos dependendo da direção da variação de intensidade.

Portanto, ao utilizar ReLU, apenas bordas associadas a gradientes positivos permanecem visíveis, enquanto bordas associadas a gradientes negativos são descartadas.

Esses experimentos demonstram que a escolha dos parâmetros do filtro influencia diretamente o tipo de informação que será extraída da imagem.

6. Conclusão

Este trabalho apresentou a implementação manual de operações fundamentais de processamento digital de imagens, com foco na correlação dilatada (Atrous).

A implementação permitiu compreender em maior profundidade o funcionamento interno dessas operações, especialmente a influência de parâmetros como stride, taxa de dilatação e funções de ativação.

Os experimentos realizados demonstraram como esses parâmetros afetam diretamente o resultado do processamento, alterando aspectos como resolução da imagem, detecção de bordas e suavização de detalhes.

Além disso, a comparação com a biblioteca OpenCV indicou que, quando configuradas em condições equivalentes, as duas abordagens produzem resultados bastante semelhantes, o que valida a implementação desenvolvida.

De forma geral, o projeto contribuiu para consolidar conceitos fundamentais de processamento digital de imagens e mostrou a importância da implementação prática para a compreensão desses algoritmos.